

Hola

Linealización de ecuaciones para regresión no lineal

¿Qué significa linealizar?

Linealización de ecuaciones para regresión no lineal

¿Qué significa linealizar?

En muchos casos, una ecuación **no lineal** puede **linealizarse** usando un poco de matemática.

Linealización de ecuaciones para regresión no lineal

¿Qué significa linealizar?

En muchos casos, una ecuación **no lineal** puede **linealizarse** usando un poco de matemática.

Esto permite utilizar métodos de regresión lineal sobre las **variables transformadas** y en base a los parámetros del ajuste recuperar los **parámetros originales**.

Linealización de ecuaciones para regresión no lineal

¿Qué significa linealizar?

En muchos casos, una ecuación **no lineal** puede **linealizarse** usando un poco de matemática.

Esto permite utilizar métodos de regresión lineal sobre las **variables transformadas** y en base a los parámetros del ajuste recuperar los **parámetros originales**.

$$y = f(x|a, b) \quad \longrightarrow \quad Y = \beta_0 + \beta_1 X$$

Linealización de ecuaciones para regresión no lineal

¿Qué significa linealizar?

En muchos casos, una ecuación **no lineal** puede **linealizarse** usando un poco de matemática.

Esto permite utilizar métodos de regresión lineal sobre las **variables transformadas** y en base a los parámetros del ajuste recuperar los **parámetros originales**.

$$y = f(x|a, b) \longrightarrow Y = \beta_0 + \beta_1 X$$

donde Y y X son transformaciones de las variables originales x, y .

Linealización de ecuaciones para regresión no lineal

Ejemplo 1: Exponencial

Supongamos que nuestros datos están bien modelados por una relación exponencial:

$$y = ae^{bx}$$

donde a y b son parámetros desconocidos.

Linealización de ecuaciones para regresión no lineal

Ejemplo 1: Exponencial

Supongamos que nuestros datos están bien modelados por una relación exponencial:

$$y = ae^{bx}$$

donde a y b son parámetros desconocidos.

Si aplicamos logaritmo natural a cada lado vemos que

$$\log(y) = \log(a + e^{bx}) = \log(a) + \log(e^{bx}) = \log(a) + bx$$

Linealización de ecuaciones para regresión no lineal

Ejemplo 1: Exponencial

Supongamos que nuestros datos están bien modelados por una relación exponencial:

$$y = a e^{bx}$$

donde a y b son parámetros desconocidos.

Si aplicamos logaritmo natural a cada lado vemos que

$$\begin{aligned} \log(y) &= \log(a + e^{bx}) = \log(a) + \log(e^{bx}) = \log(a) + bx \\ &\longrightarrow \log(y) = \log(a) + b x \end{aligned}$$

Linealización de ecuaciones para regresión no lineal

Ejemplo 1: Exponencial

Supongamos que nuestros datos están bien modelados por una relación exponencial:

$$y = a e^{bx}$$

donde a y b son parámetros desconocidos.

Si aplicamos logaritmo natural a cada lado vemos que

$$\begin{aligned}\log(y) &= \log(a + e^{bx}) = \log(a) + \log(e^{bx}) = \log(a) + bx \\ &\longrightarrow \log(y) = \log(a) + b x\end{aligned}$$

Ajustando $Y = \beta_0 + \beta_1 x$ con $Y = \log(y)$, $X = x$, $\beta_0 = \log(a)$, $\beta_1 = b$.

Linealización de ecuaciones para regresión no lineal

Ejemplo 1: Exponencial

Supongamos que nuestros datos están bien modelados por una relación exponencial:

$$y = a e^{bx}$$

donde a y b son parámetros desconocidos.

Si aplicamos logaritmo natural a cada lado vemos que

$$\begin{aligned} \log(y) &= \log(a e^{bx}) = \log(a) + \log(e^{bx}) = \log(a) + bx \\ \longrightarrow \log(y) &= \log(a) + b x \end{aligned}$$

Ajustando $Y = \beta_0 + \beta_1 x$ con $Y = \log(y)$, $X = x$, $\beta_0 = \log(a)$, $\beta_1 = b$.

Podemos recuperar los parámetros originales invirtiendo la transformación:

$$a = e^{\beta_0} \quad b = \beta_1$$

Linealización de ecuaciones para regresión no lineal

Ejemplos 2 y 3: Leyes de potencia e inversa

■ Leyes de potencias: $y = ax^b$

Tomando logaritmo a ambos lados obtenemos una relación lineal entre $\log(y)$ y $\log(x)$:

$$\log(y) = \log(a) + b \log(x).$$

Podemos recuperar los parámetros originales tomando $a = e^{\beta_0}$, $b = \beta_1$

■ Inversa: $y = \frac{1}{a+bx}$

Tomando la inversa a ambos lados obtenemos una relación lineal entre $1/y$ y x :

$$\frac{1}{y} = a + bx.$$

En este caso los parámetros originales coinciden con los transformados: $a = \beta_0$, $b = \beta_1$

Linealización de ecuaciones para regresión no lineal


Ejemplo

```
1 # Creo data exponencial artificialmente
2 x = np.linspace(1, 10, 50)
3 y = 2 * np.exp(0.8 * x)
4 y = y * (1 + np.random.normal(0, 0.2, size=x.size))
5 df = data.frame(x=x, y=y)
6
7 # La grafico
8 ggplot(df, aes(x, y)) +
9     geom_point(color = "black") +
10     labs(title = "") +
11     theme_minimal()
```


Linealización de ecuaciones para regresión no lineal

Ejemplo


```
1 # Creo data exponencial artificialmente
2 x = np.linspace(1, 10, 50)
3 y = 2 * np.exp(0.8 * x)
4 y = y * (1 + np.random.normal(0, 0.2, size=x.size))
5 df = data.frame(x=x, y=y)
6
7 # La grafico
8 ggplot(df, aes(x, y)) +
9   geom_point(color = "black") +
10  labs(title = "") +
11  theme_minimal()
```



Linealización de ecuaciones para regresión no lineal

Ejemplo

```
1 # Mismo gráfico pero en semi-logy
2 ggplot(df, aes(x, log(y))) +
3   geom_point(color = "black") +
4   labs(title = "") +
5   theme_minimal()
```



Linealización de ecuaciones para regresión no lineal


Ejemplo

```
1 # Modelo linealizado
2 mod <- lm(log(y) ~ x)
3 a <- exp(mod$coef[1])
4 b <- mod$coef[2]
```


Linealización de ecuaciones para regresión no lineal

Ejemplo


```
1 # Modelo linealizado
2 mod <- lm(log(y) ~ x)
3 a <- exp(mod$coef[1])
4 b <- mod$coef[2]
5
6 # Plot en semi-logy
7 ggplot(df, aes(x, log(y))) +
8   geom_point(color = "black") +
9   stat_function(
10     fun = \(x) log(a) + b * x,
11     col = "#C95E61",
12   ) +
13   labs(title = "") +
14   theme_minimal()
```



Linealización de ecuaciones para regresión no lineal

Ejemplo

```
1 # Modelo linealizado
2 mod <- lm(log(y) ~ x)
3 a <- exp(mod$coef[1])
4 b <- mod$coef[2]
5
6 # Plot en coords. originales
7 ggplot(df, aes(x = x, y = y)) +
8   geom_point(color = "black") +
9   stat_function(
10     fun = function(x) a*exp(b*x),
11     col = "#C95E61"
12   ) +
13   labs(title = "") +
14   theme_minimal()
```



Evaluación y Diagnóstico

Introducción

Librerías y datos


```
library(tidyverse)
library(broom) # mejores métricas para los modelos

df <- read_csv("mean_salary_vs_age.csv")
df <- df %>% filter(between(age, 18, 40))
```

Gráficos con GGPlot

Edad vs salario promedio

```
1 ggplot(df, aes(x = age, y = mean_salary)) +  
2   geom_point(alpha = 0.8) +  
3   labs(x = "Edad", y = "Salario promedio") +  
4   theme_minimal()
```



Modelo lineal simple

Ajuste

```
1 mod <- lm(formula = mean_salary ~ age, data = df)
```


Evaluación del modelo

Visual

```
1 ggplot(df, aes(x = age, y = mean_salary)) +  
2   geom_point(alpha = 0.8) +  
3   geom_abline(  
4     intercept = coef(mod)[1],  
5     slope = coef(mod)[2],  
6     linewidth = 1.2, col = "#C95E61"  
7   ) +  
8   labs(x = "Edad", y = "Salario promedio") +  
9   theme_minimal()
```

Evaluación del modelo

Visual



Evaluación del modelo

`summary()` : resumen por defecto de R

```
1 summary(mod)
```

Residuals:

Min	1Q	Median	3Q	Max
-81473	-20963	-8828	18326	100592

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	14446	38428	0.376	0.711
age	21726	1292	16.819	1.16e-13 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Multiple R-squared: 0.9309, Adjusted R-squared: 0.9276

F-statistic: 282.9 on 1 and 21 DF, p-value: 1.161e-13

Evaluación del modelo

`broom::tidy()` : métricas de los parámetros

```
1 tidy(mod, conf.int = TRUE)
```

term	estimate	std.error	statistic	p.value	conf.low	conf.high
(Intercept)	14446.46	38427.893	0.3759368	7.107348e-01	-65468.72	94361.64
age	21725.64	1291.739	16.8189058	1.160960e-13	19039.33	24411.96

Evaluación del modelo

`broom::glance()` : métricas globales

```
1 glance(mod)
```

r.squared	adj.r.squared	sigma	statistic	p.value
0.930892771805846	0.927601951415648	41092.7485815856	282.875593751227	1.16095971950248e-13

Diagnóstico Supuestos

Los residuos deberían ser:

Diagnóstico Supuestos

Los residuos deberían ser:

- aproximadamente normales

Diagnóstico Supuestos

Los residuos deberían ser:

- aproximadamente normales
- con media cero

Diagnóstico Supuestos

Los residuos deberían ser:

- aproximadamente normales
- con media cero
- varianza constante


Diagnóstico Supuestos

Los residuos deberían ser:


- aproximadamente normales
- con media cero
- varianza constante
- independientes

Diagnóstico (muchos) Gráficos

1 `plot(mod)`




Diagnóstico Residuos




Diagnóstico

Residuos Q-Q




Diagnóstico

Dispersión de residuos



Diagnóstico

Leverage y Curvas de Cook



Diagnóstico

augment(): métricas sobre los residuos

```
1 df_aug <- augment(mod, data = df)
2 glimpse(df_aug)
```

age	mean_salary	.fitted	.resid	.hat	.sigma	.cooks	.std.resid
18	359052.631578947	405508.065264212	-46455.4336852644	0.163043478260869	40547.7347519102	0.148734013051861	-1.23571943984025
19	418405.797101449	427233.710023821	-8827.91292237164	0.142292490118577	42053.5568296116	0.00446333267180221	-0.231965417654955
20	424502.487562189	448959.35478343	-24456.8672212409	0.123517786561265	41700.3974946489	0.0284763655707955	-0.635717374452461
21	434716.049382716	470684.999543039	-35968.950160323	0.106719367588933	41238.6732571091	0.0512345060485365	-0.926122876695345
22	457282.352941177	492410.644302648	-35128.2913614716	0.0918972332015811	41292.8687123502	0.0407179695349446	-0.897065874310196
23	496666.304347826	514136.289062257	-17469.9847144311	0.0790513833992095	41910.3184690552	0.00842293301899034	-0.443006026304919


Diagnóstico con ggplot

Residuos

```
1 ggplot(df_aug, aes(.fitted, .resid)) +  
2   geom_point() +  
3   geom_hline(yintercept = 0, linetype = "dashed",  
4             colour = "grey", linewidth = 1.2) +  
5   geom_smooth(se = FALSE, col = "#C95E61", linewidth = 1.2) +  
6   labs(title = "Residuos vs valores predichos",  
7         x = "Predicho", y = "Residuo") +  
8   theme_minimal()
```

Diagnóstico con ggplot

Residuos




Diagnóstico con ggplot

Residuos Q-Q

```
1 ggplot(df_aug, aes(sample = .std.resid)) +  
2   stat_qq() +  
3   geom_abline() +  
4   labs(title = "Normal QQ plot",  
5         x = "Teórico", y = "Observado") +  
6   theme_minimal()
```

Diagnóstico con ggplot

Residuos Q-Q



Pongamos en práctica lo que aprendimos sobre modelos lineales

Esto es todo.