

Regresión Lineal Múltiple

Clase 1- Interpretaciones (train)

Clase 2 - Evaluación, diagnóstico, predicción (test)

Clase 3 - Extensiones del modelo lineal

Objetivo: construir un **modelo de regresión lineal múltiple** que explique el precio de ventas de propiedades (en dólares) con variables explicativas (habitaciones, superficie, tipo de propiedad, barrio).

Objetivo: construir un **modelo de regresión lineal múltiple** que explique el precio de ventas de propiedades (en dólares) con variables explicativas (habitaciones, superficie, tipo de propiedad, barrio).

Modelo

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \cdots + \beta_p X_{pi} + \varepsilon_i$$

Y : variable de respuesta (dependiente)

$X_1, \dots, X_p$: covariables / variables explicativas o predictoras

ε : término del error

β : parámetros desconocidos

Objetivo: construir un **modelo de regresión lineal múltiple** que explique el precio de ventas de propiedades (en dólares) con variables explicativas (habitaciones, superficie, tipo de propiedad, barrio).

Modelo

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \cdots + \beta_p X_{pi} + \varepsilon_i$$

Y : variable de respuesta (dependiente)

$X_1, \dots, X_p$: covariables / variables explicativas o predictoras

ε : término del error

β : parámetros desconocidos

$\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$ para todas mis obs. $1 < i < n$, independientes entre sí

Objetivo: construir un **modelo de regresión lineal múltiple** que explique el **precio de ventas de propiedades** (en dólares) con variables explicativas (habitaciones, superficie, tipo de propiedad, barrio).

Modelo

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \cdots + \beta_p X_{pi} + \varepsilon_i$$

Por ejemplo, si usamos las variables **Superficie**, **Ambientes**, **Baños**:

$$Precio_i = \beta_0 + \beta_1 \cdot Superficie_i + \beta_2 \cdot Ambientes_i + \beta_3 \cdot Banos_i + \varepsilon_i$$

Importamos Librerías

```
library(tidyverse)
library(tidymodels)
library(rsample)
library(ggplot2)
library(GGally)
```

Dataset

Utilizamos dataset de Properati con datos de 2022 extraídos con BigQuery y almacenados en un archivo .csv

Dataset

```
# leo el archivo ar_properties
datos <- read_csv("../Fuentes/ar_properties_2022.csv", show_col_types = FALSE)
glimpse(datos)
```

Rows: 549,630

Columns: 19

```
$ id          <chr> "K3xwB0upIg42lI+8/w9aMA==", "djQg/2Sb/JkrQ1CxmVfxgw==", "QQ5e0Xy5bdANPplyHopwVQ==", ...
$ ad_type     <chr> "Propiedad", "Propiedad", "Propiedad", "Propiedad", "Propiedad", "Propiedad", "Prop...
$ start_date  <date> 2022-01-22, 2022-01-22, 2022-01-22, 2022-01-22, 2022-01-22, 2022-01-22, 2022-01-22...
$ end_date    <date> 2022-04-06, 2022-01-29, 2022-08-20, 2022-08-20, 2022-03-29, 2022-04-25, 2022-04-15...
$ created_on  <date> 2022-01-22, 2022-01-22, 2022-01-22, 2022-01-22, 2022-01-22, 2022-01-22, 2022-01-22...
$ lat         <dbl> -34.63301, -34.68167, -32.92764, -32.92775, -34.38944, -34.38340, -34.38340, -34.61...
$ lon         <dbl> -58.37000, -58.34105, -60.81926, -60.81908, -58.86361, -58.68068, -58.68068, -58.46...
$ l1          <chr> "Argentina", "Argentina", "Argentina", "Argentina", "Argentina", "Argentina", "Arge...
$ l2          <chr> "Capital Federal", "Bs.As. G.B.A. Zona Sur", "Santa Fe", "Santa Fe", "Bs.As. G.B.A...
$ l3          <chr> "Boca", "Avellaneda", NA, NA, "Pilar", "Tigre", "Tigre", "Flores", "Morón", "Flores...
$ rooms       <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, ...
$ bedrooms    <dbl> 1, 1, 2, 3, 3, 3, 3, 4, NA, 4, 2, 3, 5, 4, 3, 3, NA, NA, NA, NA, NA, NA, NA, ...
$ bathrooms   <dbl> 1, 1, 1, 2, 3, 3, 4, 3, NA, 4, 1, 3, 3, 3, 4, 4, 2, NA, NA, NA, NA, NA, NA, NA, ...
$ surface_total <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, 210, NA, NA...
$ surface_covered <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, 210, NA, NA...
$ price       <dbl> 89000, 20000, 175000, 195000, 170000, 2500, 3100, 399000, 80000, 429900, 90000, 419...
$ currency    <chr> "USD", "ARS", "USD", "USD", "USD", "USD", "USD", "USD", "USD", "USD", "USD", "ARS", "USD", ...
$ property_type <chr> "PH", "PH", "Casa", "Casa", "Casa", "Casa", "Casa", "Casa", "Casa", "Casa", "Casa", "Casa", ...
$ operation_type <chr> "Venta", "Alquiler", "Venta", "Venta", "Venta", "Alquiler temporal", "Alquiler temp...
```


Limpieza del dataset

- Nos quedamos con propiedades de **CABA** que estén a la **venta**
- Eliminamos los **datos vacíos**
- Eliminamos **outliers**
- Reducimos **cantidad de variables**

Pueden ver el paso a paso de la limpieza de datos [acá](#)

Dataset Limpio

```
datos_properati <- read.csv("properati_preprocesado_2022.csv")
glimpse(datos_properati)
```

Rows: 28,773

Columns: 9

```
$ id          <chr> "1ZHYJgyAbGUcX+v1Ggj1rA==", "BcAHh7UMLQpQ/axyyuwqkQ==", "LlmVTCwhFsqei54xoCbyLA==",...
$ l3          <chr> "Palermo", "Caballito", "Flores", "Flores", "Retiro", "Almagro", "Palermo", "Palerm...
$ rooms       <int> 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1,...
$ bathrooms   <int> 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1,...
$ surface_total <int> 38, 55, 37, 37, 29, 41, 36, 31, 30, 36, 32, 34, 27, 30, 31, 40, 35, 37, 37, 37, 37,...
$ surface_covered <int> 35, 36, 32, 33, 26, 38, 32, 29, 28, 33, 32, 27, 27, 30, 27, 36, 31, 33, 33, 33, 33,...
$ price       <int> 125000, 74500, 79900, 53700, 57000, 99000, 93000, 68000, 84900, 65000, 62000, 66756...
$ property_type <chr> "Departamento", "Departamento", "Departamento", "Departamento", "Departamento", "De...
$ precio_en_miles <int> 125, 74, 80, 54, 57, 99, 93, 68, 85, 65, 62, 67, 45, 58, 45, 78, 77, 53, 54, 54, 52...
```

Dividimos dataset en test y train

Entrenaremos el modelo con el 75% de los datos (estimamos los parámetros β).

Luego, **evaluaremos** el modelo con el 25% restantes.


```
# fijamos semilla
set.seed(22)
# Partición Train y Test, indicando proporción
train_test <- initial_split(datos_properati, prop = 0.75)
train_data <- training(train_test)
test_data <- testing(train_test)
```

Tipos de variables

1. **Variables numéricas** (baños, superficie, etc.)
2. **Variables categóricas** (tipo de propiedad, barrio)


Veamos cómo correlacionan las variables

```
# graficamos con ggpairs coloreando por property type
g <- ggpairs(datos_properati %>% select(-c(id,l3)), aes(color = property_type),
  upper = list(continuous = wrap("cor", size = 3, hjust=0.5)), legend = 25, progress=FALSE) +
  theme(axis.text.x = element_text(angle = 90, hjust = 1), legend.position = "bottom") +
  theme_bw()
# hacemos un loop para cambiar los colores del gráfico
for(i in 1:g$nrow) {
  for(j in 1:g$ncol){
    g[i,j] <- g[i,j] +
      scale_fill_brewer(palette="Dark2") +
      scale_color_brewer(palette="Dark2")
  }
}
g
```




Distribuciones

Scatter plots
(columna vs fila)



Correlación
entre
variables
numéricas

Distribuciones



Scatter plots
(columna vs fila)

Correlación
entre
variables
numéricas

Boxplots de
variables
numéricas por
categoría

Ajustamos el modelo para dos variables numéricas

$$\text{precio} = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \varepsilon_i$$

```
# ajustamos modelo lineal múltiple  
modelo_sc_r <- lm(price ~ surface_covered + rooms, data = train_data)
```

Ajustamos el modelo para dos variables numéricas

$$\text{precio} = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \varepsilon_i$$

```
# Resumen del modelo  
tidy_sc_r <- tidy(modelo_sc_r, conf.int = TRUE)  
tidy_sc_r
```

term <chr>	estimate <dbl>	std.error <dbl>	statistic <dbl> ▶
(Intercept)	4145.527	1953.42050	2.122189
surface_covered	3201.384	20.60928	155.337057
rooms	-16605.265	963.66456	-17.231375

Interpretemos los coeficientes

$$\text{precio} = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \varepsilon_i$$

term <chr>	estimate <dbl>	std.error <dbl>	statistic <dbl> ▶
(Intercept)	4145.527	1953.42050	2.122189
surface_covered	3201.384	20.60928	155.337057
rooms	-16605.265	963.66456	-17.231375

Test t (significatividad individual de los β)

H0: $\beta_j = 0$ (la variable no tiene efecto)

H1: $\beta_j \neq 0$ (la variable sí tiene efecto)

Estadístico: $t_j = \frac{\hat{\beta}_j}{SE(\hat{\beta}_j)}$

Interpretación:

- Valor $|t|$ grande $\rightarrow$ fuerte evidencia contra H0.
- p-value pequeño (< 0.05) $\rightarrow$ coeficiente significativo.
- p-value grande $\rightarrow$ no hay evidencia de efecto.

Test t (significatividad individual de los β)

```
options("scipen"=1)
tidy_sc_r %>%
  select(term, statistic, p.value, conf.low, conf.high)
```

[illegible]

Ahora queremos utilizar una variable categórica

Vamos a utilizar la variable **property_type** que tiene 3 clases:

- Casas
- Departamentos
- PH

Ahora queremos utilizar una variable categórica

Vamos a utilizar la variable **property_type** que tiene 3 clases:

- Casas
- Departamentos
- PH

Cómo interpreta el modelo esta variable:

Si hay k categorías, crea $k-1$ **variables dummies** (binarias), y la que no se usa es la **categoría de referencia** (base).

Veamos que pasa en este caso

```
# ajustamos el modelo de superficie y tipo de propiedad
modelo_sc_pt <- lm(price ~ surface_covered + property_type, data = train_data)
tidy_sc_pt <- tidy(modelo_sc_pt, conf.int = TRUE)
tidy_sc_pt
```


Veamos que pasa en este caso

```
# ajustamos el modelo de superficie y tipo de propiedad
modelo_sc_pt <- lm(price ~ surface_covered + property_type, data = train_data)
tidy_sc_pt <- tidy(modelo_sc_pt, conf.int = TRUE)
tidy_sc_pt
```

term <chr>	estimate <dbl>	std.error <dbl>	statistic <dbl> ▶
(Intercept)	-237133.159	4870.04886	-48.69215
surface_covered	3192.418	13.36372	238.88696
property_typeDepartamento	209623.598	4475.04626	46.84278
property_typePH	128781.053	5002.91545	25.74120


Intercept = β_0 + (categoría base = Casa)

Volvamos a ver cómo se comporta esta variable respecto a la variable **precio**:

```
ggplot(data = train_data, aes(y = precio_en_miles, group = property_type, fill = property_type)) +  
  geom_boxplot() +  
  scale_fill_brewer(palette="Dark2") +  
  theme_bw() +  
  scale_y_continuous(limits = c(0, 1000)) +  
  theme(axis.text.x=element_blank(),  
        axis.ticks.x=element_blank()) +  
  labs(title = "Boxplots de precio según tipo de propiedad", subtitle = "En miles de dólares") +  
  labs(y = "Precio en miles de USD") +  
  labs(x = "Tipo de propiedad") +  
  facet_wrap(~property_type)
```

Boxplots de precio según tipo de propiedad


En miles de dólares



Interpretemos los coeficientes!

term <chr>	estimate <dbl>	std.error <dbl>	statistic <dbl> ▶
(Intercept)	-237133.159	4870.04886	-48.69215
surface_covered	3192.418	13.36372	238.88696
property_typeDepartamento	209623.598	4475.04626	46.84278
property_typePH	128781.053	5002.91545	25.74120

Modelo Lineal Múltiple: Superficie y Tipo de Propiedad



Test t (significatividad individual de los β)

```
tidy_sc_pt %>%  
  select(term, statistic, p.value, conf.low, conf.high)
```

term <chr>	statistic <dbl>
(Intercept)	-48.69215
surface_covered	238.88696
property_typeDepartamento	46.84278
property_typePH	25.74120

Test t (significatividad individual de los β)

```
tidy_sc_pt %>%  
  select(term, statistic, p.value, conf.low, conf.high)
```

term <chr>	statistic <dbl>
(Intercept)	-48.69215
surface_covered	238.88696
property_typeDepartamento	46.84278
property_typePH	25.74120

Qué información me da sobre las variables categóricas?

Test F (significatividad conjunta de variable categórica)

$$H_0: \beta_1 = \beta_2 = \dots = \beta_p = 0$$

$$H_1: \exists \beta_j \neq 0 \text{ (al menos uno distinto de cero)}$$

¿Esta variable categórica (como bloque) agrega poder explicativo al modelo?

```
# Modelo Superficie y Tipo de Propiedad  
tidy(anova(modelo_sc_pt))
```

term <chr>	df <int>	sumsq <dbl>	meansq <dbl>	statistic <dbl>	p.value <dbl>
surface_covered	1	696994145636502	696994145636502	57338.968	0
property_type	2	35284912549120	17642456274560	1451.376	0
Residuals	21575	262258794503442	12155679931	NA	NA

Test F (significatividad global del modelo)

```
summary(modelo_sc_pt)
```

Call:

```
lm(formula = price ~ surface_covered + property_type, data = train_data)
```

Residuals:

Min	1Q	Median	3Q	Max
-1796287	-37382	-5581	26298	2272802

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-237133.16	4870.05	-48.69	<2e-16 ***
surface_covered	3192.42	13.36	238.89	<2e-16 ***
property_typeDepartamento	209623.60	4475.05	46.84	<2e-16 ***
property_typePH	128781.05	5002.92	25.74	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 110300 on 21575 degrees of freedom

Multiple R-squared: 0.7363, Adjusted R-squared: 0.7363

F-statistic: 2.008e+04 on 3 and 21575 DF, p-value: < 2.2e-16

Fin!