

Regresión Lineal Múltiple

Objetivos:

- **Evaluar** modelos de regresión lineal múltiple para explicar el precio de propiedades en CABA en 2022.
- Utilizar modelos para **predecir** el precio de propiedades a partir de variables conocidas.

Modelo

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \cdots + \beta_p X_{pi} + \varepsilon_i$$

Y : variable de respuesta (dependiente)

$X_1, \dots, X_p$: covariables / variables explicativas o predictoras

ε : término del error

β : parámetros desconocidos

Modelo

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \cdots + \beta_p X_{pi} + \varepsilon_i$$

Y : variable de respuesta (dependiente)

$X_1, \dots, X_p$: covariables / variables explicativas o predictoras

ε : término del error

β : parámetros desconocidos

$\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$ para todas mis obs. $1 < i < n$, independientes entre sí

La clase pasada vimos la significatividad de los coeficientes

- Test t (significatividad individual)
- Test F (significatividad global y parcial)

Test t (significatividad individual de los β)

H0: $\beta_j = 0$ (la variable no tiene efecto)

H1: $\beta_j \neq 0$ (la variable sí tiene efecto)

Estadístico: $t_j = \frac{\hat{\beta}_j}{SE(\hat{\beta}_j)}$

Interpretación:

- Valor $|t|$ grande $\rightarrow$ fuerte evidencia contra H0.
- p-value pequeño (< 0.05) $\rightarrow$ coeficiente significativo.
- p-value grande $\rightarrow$ no hay evidencia de efecto.

Algunas definiciones

$SST = \sum_{i=1}^n (y_i - \bar{y})^2 \longrightarrow$ **Variación total** de Y respecto a su media, antes de considerar ninguna variable explicativa.

$SSR = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 \longrightarrow$ La parte de la variabilidad de Y **explicada por el modelo**.

$SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2 \longrightarrow$ Variabilidad no **explicada por el modelo**.

R²

El **R²** mide qué proporción de la variabilidad total de Y es explicada por el modelo.

$$SST = \sum_{i=1}^n (y_i - \bar{y})^2 \longrightarrow \text{Variación total de Y respecto a su media, antes de considerar ninguna variable explicativa.}$$

$$SSR = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 \longrightarrow \text{La parte de la variabilidad de Y **explicada por el modelo.**}$$

$$SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2 \longrightarrow \text{Variabilidad **no explicada por el modelo.**}$$

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$$

Algunas definiciones

$$SST = \sum_{i=1}^n (y_i - \bar{y})^2 \longrightarrow \text{Variación total de Y respecto a su media, antes de considerar ninguna variable explicativa.}$$

$$SSR = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 \longrightarrow \text{La parte de la variabilidad de Y **explicada por el modelo**.}$$

$$SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2 \longrightarrow \text{Variabilidad no **explicada por el modelo**.}$$

$$MSR = \frac{SSR}{k}$$

$$MSE = \frac{SSE}{n - k - 1}$$

k variables
n observaciones

Test F (significatividad global o parcial)

“¿Explican las variables explicativas (en conjunto) una proporción significativa de la variabilidad de Y?”

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_p = 0$$

$$H_1 : \exists \beta_j \neq 0 \text{ (al menos uno distinto de cero)}$$

$$F = \frac{MSR}{MSE} = \frac{(SSR/k)}{(SSE/(n - k - 1))}$$

Test F (significatividad global o parcial)

“¿Explican las variables explicativas (en conjunto) una proporción significativa de la variabilidad de Y?”

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_p = 0$$

$$H_1 : \exists \beta_j \neq 0 \text{ (al menos uno distinto de cero)}$$

$$F = \frac{MSR}{MSE} = \frac{(SSR/k)}{(SSE/(n - k - 1))}$$

Interpretación (Test F)

- Valor F grande $\rightarrow$ fuerte evidencia contra H_0 .
- p-value pequeño (< 0.05) $\rightarrow$ el modelo es globalmente significativo: al menos una variable explica Y.
- p-value grande $\rightarrow$ no hay evidencia de que las variables explicativas mejoren la predicción frente al modelo sin regresores (solo el intercepto).
- Cuanto mayor sea F, mayor es la proporción de variabilidad explicada por el modelo en relación con la no explicada.

Importamos Librerías

```
library(tidyverse)
library(tidymodels)
library(rsample)
library(ggplot2)
library(GGally)
```


Utilizamos Dataset Limpio

```
datos_properati <- read.csv("properati_preprocesado_2022.csv")
glimpse(datos_properati)
```

Rows: 28,773

Columns: 9

```
$ id          <chr> "1ZHYJgyAbGUcX+v1Ggj1rA==", "BcAHh7UMLQpQ/axyyuwqkQ==", "LlmVTCwhFsqei54xoCbyLA==",...
$ l3          <chr> "Palermo", "Caballito", "Flores", "Flores", "Retiro", "Almagro", "Palermo", "Palerm...
$ rooms       <int> 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1,...
$ bathrooms   <int> 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1,...
$ surface_total <int> 38, 55, 37, 37, 29, 41, 36, 31, 30, 36, 32, 34, 27, 30, 31, 40, 35, 37, 37, 37, 37, 37, 37, 37, 37, 37, 37,...
$ surface_covered <int> 35, 36, 32, 33, 26, 38, 32, 29, 28, 33, 32, 27, 27, 30, 27, 36, 31, 33, 33, 33, 33, 33, 33, 33, 33, 33, 33,...
$ price       <int> 125000, 74500, 79900, 53700, 57000, 99000, 93000, 68000, 84900, 65000, 62000, 66756...
$ property_type <chr> "Departamento", "Departamento", "Departamento", "Departamento", "Departamento", "De...
$ precio_en_miles <int> 125, 74, 80, 54, 57, 99, 93, 68, 85, 65, 62, 67, 45, 58, 45, 78, 77, 53, 54, 54, 52...
```



Nuestro modelo:

$$\text{precio} = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \varepsilon_i$$

Nuestro modelo:

$$\text{precio} = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \varepsilon_i$$

La clase pasada vimos:

- superficie cubierta + habitaciones
-
- superficie cubierta + tipo de propiedad

Nuestro modelo:

$$precio = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \varepsilon_i$$

La clase pasada vimos:

- precio = superficie cubierta + habitaciones
-
- precio = superficie cubierta + tipo de propiedad

Veamos qué pasa si vemos la variable barrios:


- precio = superficie cubierta + barrio

Vemos la variable barrios:

```
length(unique(datos_properati$l3)) # 55 barrios
```

```
# armo boxplots paralelos precios en función de los barrios
ggplot(datos_properati, aes(x = fct_reorder(l3, price, .desc = T), y = price/1000)) +
  geom_boxplot(outlier.shape = NA, alpha = 0.75, aes(fill = l3)) +
  theme_minimal() +
  theme(legend.position = 'none')+
  labs(y = "Precios en miles", x = "Barrios") +
  scale_y_continuous(limits = c(0, 1200)) +
  ggtitle("Boxplots de precios en función de los barrios")+
  theme (axis.text.x = element_text(face="italic", colour="dark grey", size = 8, angle = 90))
```

Boxplots de precios en función de los barrios



precio = superficie cubierta + barrio

```
# ajustamos el modelo
modelo_sc_l3 <- lm(price ~ surface_covered + l3, data = train_data)
tidy_sc_l3 <- tidy(modelo_sc_l3, conf.int = TRUE)
tidy_sc_l3
```

Qué me dicen estos coeficientes?

term <chr>	estimate <dbl>	std.error <dbl>	statistic <dbl>
(Intercept)	-51006.6455	13669.83907	-3.73132743
surface_covered	2824.6897	12.25825	230.43168047
l3Agronomía	-1735.3301	21485.27189	-0.08076835
l3Almagro	7270.8521	14080.65101	0.51637187
l3Balvanera	-14591.9200	14409.27910	-1.01267523
l3Barracas	-7847.2270	15310.58507	-0.51253606
l3Barrio Norte	36649.3149	14185.94411	2.58349494
l3Belgrano	84544.0325	13854.03656	6.10248371
l3Boca	-32769.6998	18344.60402	-1.78633999
l3Boedo	-5321.0350	15119.94286	-0.35192163

1-10 of 56 rows | 1-4 of 7 columns

Previous **1** 2 3 4 5 6 Next

Test t (significancia individual)

$$t_j = \frac{\hat{\beta}_j}{SE(\hat{\beta}_j)}$$

term <chr>	estimate <dbl>	std.error <dbl>	statistic <dbl>
(Intercept)	-51006.6455	13669.83907	-3.73132743
surface_covered	2824.6897	12.25825	230.43168047
l3Agronomía	-1735.3301	21485.27189	-0.08076835
l3Almagro	7270.8521	14080.65101	0.51637187
l3Balvanera	-14591.9200	14409.27910	-1.01267523
l3Barracas	-7847.2270	15310.58507	-0.51253606
l3Barrio Norte	36649.3149	14185.94411	2.58349494
l3Belgrano	84544.0325	13854.03656	6.10248371
l3Boca	-32769.6998	18344.60402	-1.78633999
l3Boedo	-5321.0350	15119.94286	-0.35192163

1-10 of 56 rows | 1-4 of 7 columns

Previous **1** 2 3 4 5 6 Next

Test t (significancia individual)

term <chr>	estimate <dbl>	std.error <dbl>	statistic <dbl>
(Intercept)	-51006.6455	13669.83907	-3.73132743
surface_covered	2824.6897	12.25825	230.43168047
l3Agronomía	-1735.3301	21485.27189	-0.08076835
l3Almagro	7270.8521	14080.65101	0.51637187
l3Balvanera	-14591.9200	14409.27910	-1.01267523
l3Barracas	-7847.2270	15310.58507	-0.51253606
l3Barrio Norte	36649.3149	14185.94411	2.58349494
l3Belgrano	84544.0325	13854.03656	6.10248371
l3Boca	-32769.6998	18344.60402	-1.78633999
l3Boedo	-5321.0350	15119.94286	-0.35192163

1-10 of 56 rows | 1-4 of 7 columns

Previous **1** 2 3 4 5 6 Next

Test t (significancia individual)

[illegible]

Probamos agrupando los barrios por precio por metro cuadrado


Creamos variable de precio por metro cuadrado

```
# Creamos una nueva variable de precios por metro cuadrado
train_data = train_data %>%
  mutate(pxm2 = round(price/surface_total,0))
# Armamos un dataframe que muestre los promedios de pxm2 en cada barrio
AVG_pxm2_l3 = train_data %>%
  group_by(l3) %>%
  summarise(AVG_pxm2_l3 = mean(pxm2))
AVG_pxm2_l3
```


Visualizamos en un boxplot

```
# boxplot de precios por metro cuadrado
ggplot(data = AVG_pxm2_l3, aes(x = AVG_pxm2_l3)) +
  geom_boxplot(alpha = 0.75, fill="firebrick") +
  labs(title = "Boxplot de precios promedio de barrios por m2") +
  labs(x = "Precios promedio de barrios por m2") +
  theme_bw()
```

Vemos dispersión de precio por metro cuadrado para sectorizar



Vemos dispersión de precio por metro cuadrado para sectorizar



Categorías:

- precios_bajos (Q1)
- precios_medios (RI)
- precios_altos (Q3)

Agregamos la nueva variable

```
# armamos nueva variable siguiendo tales criterios
AVG_pxm2_l3 = AVG_pxm2_l3 %>%
  mutate(tipo_barrio = case_when(
    AVG_pxm2_l3 < quantile(AVG_pxm2_l3)[2] ~ "precio_bajo",
    AVG_pxm2_l3 >= quantile(AVG_pxm2_l3)[2] & AVG_pxm2_l3 < quantile(AVG_pxm2_l3)[4] ~ "precio_medio",
    TRUE ~ "precio_alto"
  )
)
write.csv(AVG_pxm2_l3, 'AVG_pxm2_l3.csv')

# unimos esta clasificación al dataset original
train_data = train_data %>% left_join(AVG_pxm2_l3, by = 'l3')
head(train_data)
```

precio = superficie cubierta + tipo de barrio

```
# ajustamos el modelo
modelo_sc_tb <- lm(price ~ surface_covered + tipo_barrio, data = train_data)
tidy_sc_tb <- tidy(modelo_sc_tb, conf.int = TRUE)
tidy_sc_tb
```

precio = superficie cubierta + tipo de barrio

```
# ajustamos el modelo
modelo_sc_tb <- lm(price ~ surface_covered + tipo_barrio, data = train_data)
tidy_sc_tb <- tidy(modelo_sc_tb, conf.int = TRUE)
tidy_sc_tb
```

term <chr>	estimate <dbl>	std.error <dbl>	statistic <dbl>
(Intercept)	7435.986	1389.52824	5.351446
surface_covered	2862.753	12.52001	228.654187
tipo_barrioprecio_bajo	-99441.545	3280.14879	-30.316169
tipo_barrioprecio_medio	-66924.423	1751.00134	-38.220658

Test t (significancia individual)

$$t_j = \frac{\hat{\beta}_j}{SE(\hat{\beta}_j)}$$

term <chr>	estimate <dbl>	std.error <dbl>	statistic <dbl>
(Intercept)	7435.986	1389.52824	5.351446
surface_covered	2862.753	12.52001	228.654187
tipo_barrioprecio_bajo	-99441.545	3280.14879	-30.316169
tipo_barrioprecio_medio	-66924.423	1751.00134	-38.220658

Agregamos una nueva variable

```
# creamos nueva variable de superficie descubierta
datos_properati = datos_properati %>%
  mutate(surface_uncovered = surface_total - surface_covered)
```

Agregamos una nueva variable

```
# creamos nueva variable de superficie descubierta
datos_properati = datos_properati %>%
  mutate(surface_uncovered = surface_total - surface_covered)
```

Y creamos los modelos:

- $\text{precio} = \text{sup. cubierta} + \text{sup. descubierta} + \text{habitaciones} + \text{tipo de propiedad}$
- $\text{precio} = \text{sup. cubierta} + \text{sup. descubierta} + \text{habitaciones} + \text{tipo de propiedad} + \text{barrio}$
- $\text{precio} = \text{sup. cubierta} + \text{sup. descubierta} + \text{habitaciones} + \text{tipo de propiedad} + \text{tipo de barrio}$

Entrenamos los modelos

```
# Modelo de superficie y Habitaciones
modelo_sc_r <- lm(price ~ surface_covered + rooms, data = train_data)

# Modelo de superficie y tipo de propiedad
modelo_sc_pt <- lm(price ~ surface_covered + property_type, data = train_data)

# Modelo de superficie y barrios
modelo_sc_l3 <- lm(price ~ surface_covered + l3, data = train_data)

# Modelo de superficie y tipo de barrio
modelo_sc_tb <- lm(price ~ surface_covered + tipo_barrio, data = train_data)

# Modelo varias
modelo_varias <- lm(price ~ surface_covered + surface_uncovered + rooms + property_type, data = train_data)

# Modelo varias + barrios
modelo_varias_l3 <- lm(price ~ surface_covered + surface_uncovered + rooms + property_type + l3, data = train_data)

# Modelo varias + tipo de barrio
modelo_varias_tb <- lm(price ~ surface_covered + surface_uncovered + rooms + property_type + tipo_barrio, data = train_data)
```

Evaluación de modelos

```
# armamos lista con todos los modelos  
models <- list(modelo_sc_r = modelo_sc_r, modelo_sc_pt = modelo_sc_pt, modelo_sc_l3 = modelo_sc_l3, modelo_sc_tb = modelo_sc_tb, modelo_varias = modelo_varias, modelo_varias_l3 = modelo_varias_l3, modelo_varias_tb = modelo_varias_tb)
```

Evaluación de modelos (train)

```
# calculamos las métricas para todos los modelos
df_evaluacion_train = map_df(models, glance, .id = "model") %>%
  # ordenamos por R2 ajustado
  arrange(desc(adj.r.squared))

df_evaluacion_train
```

model <chr>	r.squared <dbl>	adj.r.squared <dbl>	sigma <dbl>	statistic <dbl>	p.value <dbl>	df <dbl>	logLik <dbl>	AIC <dbl>	BIC <dbl>
modelo_varias_l3	0.7822127	0.7816155	100326.6	1309.973	0	59	-279097.0	558316.0	558802.8
modelo_varias_tb	0.7654093	0.7653332	103999.4	10054.379	0	7	-279898.9	559815.8	559887.6
modelo_varias	0.7513093	0.7512517	107074.3	13034.662	0	5	-280528.7	561071.3	561127.2
modelo_sc_l3	0.7498718	0.7492326	107508.0	1173.180	0	55	-280590.9	561295.7	561750.6
modelo_sc_pt	0.7363008	0.7362642	110252.8	20080.573	0	3	-281160.9	562331.9	562371.8
modelo_sc_tb	0.7270092	0.7269712	112178.4	19152.322	0	3	-281534.6	563079.1	563119.0
modelo_sc_r	0.7048834	0.7048561	116633.1	25767.045	0	2	-282375.4	564758.8	564790.7

Evaluación de modelos (train)

```
# calculamos las métricas para todos los modelos
df_evaluacion_train = map_df(models, glance, .id = "model") %>%
  # ordenamos por R2 ajustado
  arrange(desc(adj.r.squared))

df_evaluacion_train
```

model <chr>	r.squared <dbl>	adj.r.squared <dbl>	sigma <dbl>	statistic <dbl>	p.value <dbl>	df <dbl>	logLik <dbl>	AIC <dbl>	BIC <dbl>
modelo_varias_l3	0.7822127	0.7816155	100326.6	1309.973	0	59	-279097.0	558316.0	558802.8
modelo_varias_tb	0.7654093	0.7653332	103999.4	10054.379	0	7	-279898.9	559815.8	559887.6
modelo_varias	0.7513093	0.7512517	107074.3	13034.662	0	5	-280528.7	561071.3	561127.2
modelo_sc_l3	0.7498718	0.7492326	107508.0	1173.180	0	55	-280590.9	561295.7	561750.6
modelo_sc_pt	0.7363008	0.7362642	110252.8	20080.573	0	3	-281160.9	562331.9	562371.8
modelo_sc_tb	0.7270092	0.7269712	112178.4	19152.322	0	3	-281534.6	563079.1	563119.0
modelo_sc_r	0.7048834	0.7048561	116633.1	25767.045	0	2	-282375.4	564758.8	564790.7

R² ajustado

El **R²** mide qué proporción de la variabilidad total de Y es explicada por el modelo.

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$$

$$SST = \sum_{i=1}^n (y_i - \bar{y})^2$$

$$SSR = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$$

R² ajustado

El R² mide qué proporción de la variabilidad total de Y es explicada por el modelo.

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$$

El R² ajustado **penaliza** por cantidad de variables.

$$R_{aj}^2 = 1 - \left(\frac{SSE/(n - k - 1)}{SST/(n - 1)} \right)$$

Evaluación de modelos (train)

```
# calculamos las métricas para todos los modelos
df_evaluacion_train = map_df(models, glance, .id = "model") %>%
  # ordenamos por R2 ajustado
  arrange(desc(adj.r.squared))

df_evaluacion_train
```

model <chr>	r.squared <dbl>	adj.r.squared <dbl>	sigma <dbl>	statistic <dbl>	p.value <dbl>	df <dbl>	logLik <dbl>	AIC <dbl>	BIC <dbl>
modelo_varias_l3	0.7822127	0.7816155	100326.6	1309.973	0	59	-279097.0	558316.0	558802.8
modelo_varias_tb	0.7654093	0.7653332	103999.4	10054.379	0	7	-279898.9	559815.8	559887.6
modelo_varias	0.7513093	0.7512517	107074.3	13034.662	0	5	-280528.7	561071.3	561127.2
modelo_sc_l3	0.7498718	0.7492326	107508.0	1173.180	0	55	-280590.9	561295.7	561750.6
modelo_sc_pt	0.7363008	0.7362642	110252.8	20080.573	0	3	-281160.9	562331.9	562371.8
modelo_sc_tb	0.7270092	0.7269712	112178.4	19152.322	0	3	-281534.6	563079.1	563119.0
modelo_sc_r	0.7048834	0.7048561	116633.1	25767.045	0	2	-282375.4	564758.8	564790.7

Evaluación de modelos (train)

```
# calculamos las métricas para todos los modelos
df_evaluacion_train = map_df(models, glance, .id = "model") %>%
  # ordenamos por R2 ajustado
  arrange(desc(adj.r.squared))

df_evaluacion_train
```

model <chr>	r.squared <dbl>	adj.r.squared <dbl>	sigma <dbl>	statistic <dbl>	p.value <dbl>	df <dbl>	logLik <dbl>	AIC <dbl>	BIC <dbl>
modelo_varias_l3	0.7822127	0.7816155	100326.6	1309.973	0	59	-279097.0	558316.0	558802.8
modelo_varias_tb	0.7654093	0.7653332	103999.4	10054.379	0	7	-279898.9	559815.8	559887.6
modelo_varias	0.7513093	0.7512517	107074.3	13034.662	0	5	-280528.7	561071.3	561127.2
modelo_sc_l3	0.7498718	0.7492326	107508.0	1173.180	0	55	-280590.9	561295.7	561750.6
modelo_sc_pt	0.7363008	0.7362642	110252.8	20080.573	0	3	-281160.9	562331.9	562371.8
modelo_sc_tb	0.7270092	0.7269712	112178.4	19152.322	0	3	-281534.6	563079.1	563119.0
modelo_sc_r	0.7048834	0.7048561	116633.1	25767.045	0	2	-282375.4	564758.8	564790.7

Predicción en el dataset de testing

Evaluamos primero:

precio = sup. cubierta + sup. descubierta + habitaciones + tipo de propiedad

```
# Agregamos la predicciones al dataset de testeo
pred_varias_l3 = augment(modelo_varias_l3, newdata = test_data)
pred_varias_l3 %>% select(l3, rooms, surface_covered, surface_uncovered, property_type, price, .fitted, .resid)
```

l3 <chr>	roo... <int>	surface_covered <int>	surface_uncovered <int>	property_type <chr>	price <int>	.fitted <dbl>
Palermo	1	35	3	Departamento	125000	143128.8893
Caballito	1	36	19	Departamento	74500	100282.0066
Floresta	1	33	3	Departamento	65000	44673.8966
Flores	1	33	4	Departamento	59100	41432.9694
Flores	1	33	4	Departamento	53700	41432.9694

Predicción en el dataset de testing

Evaluamos primero:

precio = sup. cubierta + sup. descubierta + habitaciones + tipo de propiedad

 y_i $\hat{y}_i$

I3 <chr>	roo... <int>	surface_covered <int>	surface_uncovered <int>	property_type <chr>	price <int>	.fitted <dbl>
Palermo	1	35	3	Departamento	125000	143128.8893
Caballito	1	36	19	Departamento	74500	100282.0066
Floresta	1	33	3	Departamento	65000	44673.8966
Flores	1	33	4	Departamento	59100	41432.9694
Flores	1	33	4	Departamento	53700	41432.9694

RMSE (root mean square error)

$$\text{RMSE} = \sqrt{\frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n}}$$

```
rmse(data = pred_varias_l3, truth = price, estimate = .fitted)
```

.metric <chr>	.estimator <chr>	.estimate <dbl>
rmse	standard	102178

Calculamos el RMSE en el dataset de train para todos los modelos

```
# Aplicamos la función augment a los modelos  
lista_predicciones_training = map(.x = models, .f = augment)
```

```
map_dfr(.x = lista_predicciones_training, .f = rmse, truth = price, estimate = .fitted, .id="modelo") %>% arrange(.estimate)
```

Calculamos el RMSE en el dataset de train para todos los modelos

modelo <chr>	.metric <chr>	.estimator <chr>	.estimate <dbl>
modelo_varias_l3	rmse	standard	100187.0
modelo_varias_tb	rmse	standard	103980.1
modelo_varias	rmse	standard	107059.4
modelo_sc_l3	rmse	standard	107368.4
modelo_sc_pt	rmse	standard	110242.6
modelo_sc_tb	rmse	standard	112168.0
modelo_sc_r	rmse	standard	116625.0

Calculamos el RMSE en el dataset de train para todos los modelos

modelo <chr>	.metric <chr>	.estimator <chr>	.estimate <dbl>
modelo_varias_l3	rmse	standard	100187.0
modelo_varias_tb	rmse	standard	103980.1
modelo_varias	rmse	standard	107059.4
modelo_sc_l3	rmse	standard	107368.4
modelo_sc_pt	rmse	standard	110242.6
modelo_sc_tb	rmse	standard	112168.0
modelo_sc_r	rmse	standard	116625.0

Calculamos el RMSE en el dataset de test para todos los modelos

modelo <chr>	.metric <chr>	.estimator <chr>	.estimate <dbl>
modelo_varias_l3	rmse	standard	102178.0
modelo_varias_tb	rmse	standard	106151.0
modelo_sc_l3	rmse	standard	108464.8
modelo_varias	rmse	standard	109433.6
modelo_sc_pt	rmse	standard	110875.6
modelo_sc_tb	rmse	standard	113283.1
modelo_sc_r	rmse	standard	118154.6

Fin!