

Inferencia Causal - Clase 1

Lucía Babino

lbabinog@gmail.com

¿Por qué estudiar inferencia causal?

La mayoría de las veces que realizamos un análisis estadístico, estamos motivados por una **pregunta causal**.

Preguntas causales:

- ¿Fumar aumenta la probabilidad de cáncer de pulmón?
- ¿Cómo afecta la cantidad de luz solar al crecimiento de las plantas en un bosque?
- ¿Cómo afecta la contaminación por mercurio la biodiversidad de especies acuáticas en los ecosistemas fluviales?
- ¿Cómo afecta la falta de sueño a la capacidad de atención en los jóvenes?
- ¿Hay discriminación salarial por género?
- ¿Cómo impacta la educación en el salario?

¿Por qué estudiar inferencia causal?

Preguntas causales:

- ¿Fumar aumenta la probabilidad de cáncer de pulmón?
- ¿Cómo afecta la cantidad de luz solar al crecimiento de las plantas en un bosque?
- ¿Cómo afecta la contaminación por mercurio la biodiversidad de especies acuáticas en los ecosistemas fluviales?

Hay consenso en que, si realizamos un **estudio aleatorizado**, podemos inferir **causalidad**.

Pero en muchas situaciones, no es posible o no es práctico realizar un estudio aleatorizado.

En estos casos, necesitamos recurrir a **estudios observacionales**.

La **estadística** no alcanza para responder (ni para formular correctamente) estas preguntas en base a estudios observacionales.

Necesitamos complementarla con la teoría y las herramientas que brinda la **inferencia causal**.

Estadística y causalidad

Los libros de texto (introdutorios) de estadística, como mucho...

- repiten el mantra «asociación no implica causalidad»,
- explican brevemente el concepto de **confusión**,
- dicen que para poder determinar si hay una **relación causal** entre dos variables, es necesario realizar un **estudio aleatorizado**.

¿Qué brinda la Inferencia causal?

1. Un marco teórico que permite formular **preguntas causales** en lenguaje matemático.



Enfoque contrafactual (Rubin, 1974)

2. Herramientas gráficas (DAGs y reglas de d-separación) que permiten hallar el **método correcto de análisis** de los datos para poder inferir causalidad.



Enfoque gráfico (Pearl, 1980)

3. Técnicas estadísticas específicas para responder estas preguntas a partir de datos (IPW, matching, etc).

Bibliografía recomendada

- Hernán MA, Robins JM (2020). Causal Inference: What If. Boca Raton: Chapman & Hall/CRC, disponible únicamente online en <https://www.hsph.harvard.edu/miguel-hernan/causal-inference-book/>
- Pearl, J., Glymour, M., & Jewell, N. P. (2016). Causal inference in statistics: A primer. John Wiley & Sons.
- Cunningham, S. (2021). Causal inference: The mixtape. Yale university press.
<https://mixtape.scunning.com/>
- Neal, B. (2020). Introduction to causal inference. Course Lecture Notes (draft).
- *Causal Diagrams: Draw Your Assumptions Before Your Conclusions*, HarvardX.
<https://www.edx.org/es/learn/data-analysis/harvard-university-causal-diagrams-draw-your-assumptions-before-your-conclusions> de Miguel Hernan (curso online de 7 clases).


Esquema

- Clase 1: DAGs y Reglas de d-separación (confusión, mediación y sesgo de selección)
- Clase 2: Repaso teórico y Actividad en R

Problemas motivadores

Ejemplo: COVID27¹

- En un futuro hipotético aparece una nueva enfermedad: COVID-27.
- Se desarrollaron dos tratamientos: A y B.
- Somos los encargados de elegir qué tratamiento usará nuestro país exclusivamente.
- Objetivo: minimizar las muertes.
- Para tomar la decisión, contamos con un conjunto de datos de un país llamado *Ambrosia* en el que se aplicaron ambos tratamientos.



Los datos

Diccionario

Datos

- **Tratamiento:** tratamiento recibido (0 = A, 1 = B)
- **Muerte:** indicadora de muerte por COVID27
(1 = Muere; 0 = No muere)
- **Condición:** condición de salud del paciente al momento asignarse el tratamiento
(1 = Grave; 0 = Leve)

La historia de los datos

Los médicos tuvieron en cuenta el estado de salud del paciente (variable **Condicion**) al momento de decidir qué tratamiento asignar.



Análisis de datos


- **Pregunta causal:**

¿qué tratamiento es más efectivo para reducir la mortalidad?

- **Objetivo:** estimar el **efecto (causal)** del **Tratamiento** en la **Mortalidad**.
- **Análisis**
 - Variable de respuesta: **Muerte**
 - Variable explicativa: **Tratamiento**

¿¿¿Debemos **controlar** por **Condición**???


Sin controlar por Condición



Trat	Mort
0	16%
1	19%

$$RR_{B/A} = \frac{0.19}{0.16} = 1.19$$

Sin controlar por Condición



$$RR_{B/A} = \frac{0.19}{0.16} = 1.19$$


```
glm(Muerte ~ Tratamiento, family = binomial, data = covid)
```

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.66	0.07	-23.55	<2e-16 ***
Tratamiento1	0.21	0.13	1.66	0.0979 .

$$e^{0.21} = OR_{B/A} = 1.23$$

Obs.: $RR_{B/A}$ y $OR_{B/A}$ son medidas de **asociación** entre el **Tratamiento** y la **Mortalidad**.

Controlando por Condición




Cond	Trat	Mort
0	0	15%
0	1	10%
1	0	30%
1	1	20%

$$RR_{B/A(Leve)} = 0.10/0.15 = 0.67$$

$$RR_{B/A(Grave)} = 0.20/0.30 = 0.67$$

Controlando por Condición



$$RR_{B/A(Leve)} = 0.10/0.15 = 0.67$$


$$RR_{B/A(Grave)} = 0.20/0.30 = 0.67$$

```
glm(Muerte ~ Tratamiento + Condicion, family = binomial, data = covid)
```

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.73	0.07	-23.39	<2e-16 ***
Tratamiento1	-0.52	0.22	-2.39	0.0171 *
Condicion1	0.87	0.21	4.17	3.06e-05 ***

$$e^{-0.52} = OR_{B/A(Leve)} = OR_{B/A(Grave)} = 0.59$$

Paradoja de Simpson



El sentido de la asociación entre el **Tratamiento** y la **Mortalidad** cambia según si controlamos o no por **Condición**.


¿¿¿Qué tratamiento es mejor???

Entendiendo la paradoja

Los médicos tuvieron en cuenta la **Condición** de salud del paciente para decidir el **Tratamiento**.



Conocimiento experto




Los grupos tratados con A y B no son comparables (*intercambiables*).

¿Qué ocurre si controlamos por **Condición**?

Conclusión

- **Pregunta causal:** ¿qué tratamiento es más efectivo para reducir la mortalidad?
- ¿Debemos **controlar** por **Condición**? Sí.



- **Conclusión:** con el tratamiento B la probabilidad de morir es menor que con el A.

Otro ejemplo

- *Program.ar* es un programa educativo para escuelas secundarias donde por 6 meses se les enseñan herramientas de programación básicas a todos los alumnos de 5to año.
- Para evaluar el efecto de este programa, elegimos a un conjunto de escuelas secundarias representativas del país y a la mitad de ellas (elegidas al azar) aplicamos *program.ar*.
- 10 años después queremos ver si este programa tuvo un efecto en los salarios de los jóvenes.



Los datos

Diccionario

Datos

- **Curso:** 1 = recibió el curso, 0 = no lo recibió
- **Salario:** salario (1 = alto; 0 = bajo)
- **Sector:** sector de empleo
(1 = Tecnología; 0 = No Tecnología)

Análisis de datos


- **Pregunta causal:**

¿cuál es el efecto del curso en el salario futuro?

- **Objetivo:** estimar el **efecto (causal)** del **Curso** en el **Salario**.
- **Análisis**
 - Variable explicativa: **Curso**
 - Variable de respuesta: **Salario**

¿¿¿Debemos **controlar** por **Sector**???


Sin controlar por Sector



Curso	Sal_A
0	44%
1	61%

$$RR_{Sí/No} = \frac{0.61}{0.44} = 1.39$$

Sin controlar por Sector




$$RR_{Si/No} = \frac{0.61}{0.44} = 1.39$$

```
glm(Salario ~ Curso, family = binomial, data = programar)
```

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-0.24	0.09	-2.58	0.00997 **
Curso1	0.67	0.13	5.20	2e-07 ***

Controlando por Sector




Sector	Curso	Sal_A
0	0	24%
0	1	17%
1	0	81%
1	1	79%

$$RR_{Sí/No(NoTec)} = 0.17/0.24 = 0.71$$

$$RR_{Sí/No(Tec)} = 0.79/0.81 = 0.98$$

Controlando por Sector





$$RR_{Si/No(NoTec)} = 0.17/0.24 = 0.71$$

$$RR_{Si/No(Tec)} = 0.79/0.81 = 0.98$$

```
glm(Salario ~ Curso + Sector, family = binomial, data = programar)
```

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.19	0.12	-9.54	<2e-16 ***
Curso1	-0.27	0.17	-1.56	0.118
Sector1	2.71	0.17	15.87	<2e-16 ***

Paradoja de Simpson







El sentido de la asociación entre el **Curso** y el **Salario** cambia según si controlamos o no por **Sector**.

¿Cuál es el **efecto causal** del **Curso** en el **Salario**?

(pensar en grupos 5 minutos)

Entendiendo la paradoja




¿Debemos o no controlar por Sector?

No, pues el Programa se asignó de manera aleatoria.

¿Qué pasa si controlamos por Sector?

Conclusión



- **Pregunta causal:** ¿cuál es el efecto del curso en el salario futuro?
- ¿Debemos **controlar** por **Sector**? No.





- **Conclusión:** hacer el curso de programación aumenta la probabilidad de tener un salario alto.

Recapitulando

Ejemplo COVID



Ejemplo Program.ar



Mismas **asociaciones** y misma **pregunta**, pero distinto análisis. ¿Qué cambió?

¡Los **supuestos causales**!

Supuestos causales


Supuestos causales: supuestos sobre las relaciones causales entre las variables.

- Ej. COVID: **Condicion** es una **causa** del **Tratamiento**.
- Ej. Program.ar: **Sector** es una **consecuencia** del **Curso**.

Supuestos causales

- Ej. COVID: **Condicion** es una **causa** del **Tratamiento**.
- Ej. Program.ar: **Sector** es una **consecuencia** del **Curso**.

COVID-27




T = Tratamiento

Y = Muerte

Z = Condición

Program.ar



T = Curso


Y = Salario

Z = Sector

Supuestos causales

- Ej. COVID: **Condicion** es una **causa común** entre **Tratamiento** y **Muerte**.
- Ej. Program.ar: **Sector** es **mediador** entre el **Curso** y el **Salario**.

COVID-27




T = Tratamiento

Y = Muerte

Z = Condición

Program.ar




T = Curso

Y = Salario


Z = Sector

DAGs

COVID-27



Program.ar



Los **DAGs** nos permiten...

- visualizar los *supuestos causales*
- hallar el método correcto de análisis






Reglas de d-separación

DAG causal

DAG: definición

DAG = Directed Acyclic Graph

- Grafo: conjunto de nodos conectados por ramas (**G** = Graph)
- Con ramas dirigidas (**D** = Directed)
- Sin ciclos (**A** = Acyclic)




¿Cuál/es de esos grafos es un DAG?

DAG causal: definición

DAG causal: DAG en el cual los **nodos** representan **variables** y las **flechas** la **relación causal** entre ellas, que satisface las siguientes propiedades:

1. **Presencia de flecha de X a Y:** puede haber un efecto causal de X a Y.
2. **Ausencia de flecha de X a Y:** NO hay efecto causal de X a Y.
3. Toda **causa común** entre dos variables del DAG debe estar también en el DAG (incluso aunque no haya sido medida).



¿Qué supuestos causales codifica este DAG?

Ejemplo COVID-27

Z

T = Tratamiento

Y = Muerte


Z = Condición

T

Y

Los médicos tuvieron en cuenta la Condición (Z) para decidir el Tratamiento (T).

Ejemplo COVID-27




T = Tratamiento

Y = Muerte

Z = Condición

Los médicos tuvieron en cuenta la **Condición (Z)** para decidir el **Tratamiento (T)**.

Ejemplo COVID-27




T = Tratamiento

Y = Muerte

Z = Condición

La Condición (Z) afecta al desenlace (Muerte = Y)

Ejemplo COVID-27




T = Tratamiento

Y = Muerte

Z = Condición

La **Condición (Z)** afecta al desenlace (**Muerte = Y**)

Ejemplo COVID-27




T = Tratamiento

Y = Muerte

Z = Condición

¿Falta alguna flecha?

Ejemplo COVID-27



T = Tratamiento

Y = Muerte

Z = Condición

Ejemplo Program.ar

Z

T

Y

T = Curso

Y = Salario


Z = Sector

¿Qué fechas debemos incluir?

$T \rightarrow Y$?

Ejemplo Program.ar

Z



T = Curso

Y = Salario


Z = Sector

¿Qué fechas debemos incluir?

$T \rightarrow Y?$

$Z \rightarrow Y?$

Ejemplo Program.ar



T = Curso

Y = Salario

Z = Sector


¿Qué fechas debemos incluir?

$T \rightarrow Y?$

$Z \rightarrow Y?$

$Z \rightarrow T?$

Ejemplo Program.ar




T = Curso

Y = Salario

Z = Sector

Supuestos causales

COVID-27




T = Tratamiento

Y = Muerte

Z = Condición

Curso program.ar



T = Curso


Y = Salario

Z = Sector

- Los DAGs causales permiten **visualizar** y **comunicar** los **supuestos causales**.
- Los **supuestos causales** no provienen de los **datos**, si no del **conocimiento experto**.


¿Por qué los DAGs son tan útiles?

- Los DAGs son modelos
 - **causales**: representan la estructura causal de las variables
 - **estadísticos**: de ellos se deducen asociaciones entre las variables
- Cuando analizamos datos podemos tener **sesgos** y, como veremos, estos sesgos están provocados por asociaciones.
- Los DAGs nos sirven para...
 - identificar posibles fuentes de sesgo
 - guiar nuestro análisis para evitar estos sesgos



Flujo de asociación y causalidad

Flechas: tubos por los cuales fluye la **causalidad** y la **asociación**.



- la **causalidad** sólo fluye en el sentido de las flechas (relación *asimétrica*)
- la **asociación** fluye en ambos sentidos (relación *simétrica*)

X $\longrightarrow$ Y

Asociaciones e independencias que se deducen de un DAG


Estudio aleatorizado



Realizamos un estudio aleatorizado para
estimar el efecto de

A = Aspirina en **Y = Ataque cardíaco**

¿Cuál sería el DAG causal?



¿Deberíamos agregar alguna otra variable al DAG?

¿A puede recibir alguna flecha?


¿Y puede recibir alguna flecha?

Estudio aleatorizado



Sea L = Presión alta

Si incluimos a L en el DAG, ¿qué flechas deberíamos agregar?



A = Aspirina

Y = Ataque cardíaco

L = Presión alta

Pero, ¿es necesario incluir a L en el DAG?

No, porque no es **causa común** entre ningún par de variables del DAG y no tiene que ver con la **pregunta causal**.


|| **Obs:** variables registradas $\neq$ variables del DAG

Estudio aleatorizado



Realizamos un estudio aleatorizado para estimar el efecto de

$A = \text{Aspirina}$ en $Y = \text{Ataque cardíaco}$.



Construimos este DAG en base a nuestro conocimiento experto (sin datos).

Una vez que tenemos los datos, ¿esperamos encontrar asociación entre A e Y ?

Prop 1: $A \rightarrow Y \Rightarrow$ posible asociación entre A e Y .

Estudio observacional



Tenemos datos de estudio observacional con las variables

A = Encendedor en bolsillo

L = Fumar

Y = Cáncer de pulmón

¿Cuál será el DAG?

L A Y

Estudio observacional




Tenemos datos de estudio observacional con las variables

A = Encendedor en bolsillo

L = Fumar

Y = Cáncer de pulmón

¿Cuál será el DAG?




DAG como modelo estadístico

A = Encendedor en bolsillo

L = Fumar

Y = Cáncer de pulmón




Si miramos los datos, ¿esperamos encontrar asociación entre A e Y?

Sí, pero esta asociación no proviene de un **efecto causal** de A en Y, si no de la existencia de una **causa común** entre A e Y.

La **asociación** fluye de A a Y a través de la causa común L, sin embargo la **causalidad** no.

Prop 2: existencia de **causa común** entre A e Y $\Rightarrow$ posible **asociación** entre A e Y

Causa común



A e Y están **asociadas** pero no hay una relación **causal** entre ellas.




ASOCIACIÓN NO IMPLICA CAUSALIDAD

En este caso, si concluimos que A tiene un efecto causal en Y estaremos cometiendo un error, al que llamamos **sesgo**.

Sesgo sistemático (o sesgo): toda **asociación** que no se debe a un **efecto causal**.

Confusión: decimos que hay **confusión** (o **sesgo por confusión**) cuando hay una componente de la **asociación** que se debe a la existencia de una **causa común** entre las variables.

Ejemplo COVID-27



A = Tratamiento


Y = Muerte

Z = Condición

La **asociación** entre A e Y tiene dos componentes:


- la que fluye a través de $A \rightarrow Y$ (causal)
- la que fluye a través de $A \leftarrow Z \rightarrow Y$ (no causal)

Por lo tanto, si interpretamos una medida de **asociación** (marginal) entre **A** e **Y** como una medida de **causalidad**, estaremos cometiendo un **sesgo por confusión**.



Trat	Mort
0	16%
1	19%

Asociaciones condicionales




A = Encendedor en bolsillo

L = Fumar

Y = Cáncer de pulmón

- Hasta ahora, estudiamos la asociación **marginal** entre A e Y.
- ¿Qué pasa si estudiamos la asociación entre A e Y **condicional** a L?

Asociaciones condicionales



A = Encendedor en bolsillo

L = Fumar

Y = Cáncer de pulmón


Por ejemplo, si restringimos nuestro análisis a los no fumadores ($L=0$), ¿esperamos encontrar asociación entre A e Y?

No, y lo mismo ocurrirá si nos restringimos a los fumadores ($L=1$).

A es **independiente** de Y condicional a L

Prop 3: al **condicionar** en una **causa común (L)** bloqueamos el flujo de **asociación** entre A e Y.

Controlando la confusión



A = Encendedor en bolsillo

L = Fumar

Y = Cáncer de pulmón


Prop 3: al **condicionar** en la **causa común (L)** bloqueamos el flujo de asociación entre A e Y.



¡Condicionar en L es una forma de eliminar el sesgo por confusión!

Reglas de d-separación

Para evitar sesgos debemos **bloquear** todos los caminos por los cuales fluye la **asociación** pero no la **causalidad**.



T = Tratamiento

Y = Muerte


Z = Condición

¿Cómo bloqueamos esos caminos?

Reglas de d-separación: conjunto de reglas gráficas que nos dicen por qué variables debemos **controlar** para **bloquear** el flujo de **asociación** en un camino de un DAG.

Una de esas reglas dice que si controlamos por una causa común bloqueamos el flujo de asociación entre sus efectos.

Ejemplo COVID-27



T = Tratamiento


Y = Muerte

Z = Condición

Para estimar el efecto de T en Y, ¿debemos **bloquear** algún camino?

¿Cómo lo bloqueamos?

COVID-27: análisis correcto



T = Tratamiento

Y = Muerte

Z = Condición

Para estimar el **efecto causal** de T en Y, debemos **controlar** por Z.


```
glm(Muerte ~ Tratamiento + Condicion, family = binomial, data = covid)
```

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.73	0.07	-23.39	<2e-16 ***
Tratamiento1	-0.52	0.22	-2.39	0.0171 *
Condicion1	0.87	0.21	4.17	3.06e-05 ***

$$e^{-0.52} = OR_{B/A}(Leve) = OR_{B/A}(Grave) = 0.59$$

Primera configuración básica

Fork
(tenedor)




- A e Y en general están asociadas
- A e Y son independientes condicional a L.

L: causa
común

Configuraciones básicas

Fork (tenedor)



Z: causa común




Confusión

Chain (cadena)



Z: mediador

Collider (colisionador)



Z: efecto común



Sesgo de selección

Cuestionario

Responder el cuestionario 1 de esta clase disponible en el github y en [este link](#)

Mediación

Ejemplo

Queremos estimar el efecto de
Fumar en **Cáncer de pulmón**.



Supongamos que no hay ninguna causa común entre fumar y el cáncer del pulmón.
¿Cuál sería el DAG?

A

Y

A = Fumar

Y = Cáncer de pulmón

Ejemplo


Queremos estimar el efecto de
Fumar en **Cáncer de pulmón**.



Supongamos que no hay ninguna causa común entre fumar y el cáncer del pulmón.
¿Cuál sería el DAG?

A = Fumar

Y = Cáncer de pulmón



¿Esperamos encontrar asociación entre **A** e **Y** en los datos?

Ejemplo

El efecto de A en Y, está mediado por algunas variables, por ej.

B = Daño en el ADN de las células del pulmón

¿Cuál sería el DAG si incluimos a B?

A = Fumar

Y = Cáncer de pulmón

B = Daño en células del pulmón

A

B

Y

Ejemplo

El efecto de A en Y, está mediado por algunas variables, por ej.

B = Daño en el ADN de las células del pulmón

¿Cuál sería el DAG si incluimos a B?

A = Fumar

Y = Cáncer de pulmón

B = Daño en células del pulmón



(Este sería el DAG si todo el efecto está mediado por B.)

B es un *mediador* del efecto de A en Y.

¿Necesitamos incluir a B en nuestro DAG?

Depende de si queremos estimar el *efecto total* o el *efecto directo*.

Efecto total

A = Fumar

Y = Cáncer de pulmón

B = Daño en células del pulmón



Efecto total de A en Y: medida de cuánto aumenta (o disminuye) la probabilidad de tener **cáncer de pulmón** si una persona **fuma**, sin importar cuál sea el mecanismo por el cual lo contrae.

Recordemos que en un DAG sólo necesitamos incluir...

- las variables relacionadas con mi pregunta
- causas comunes

⇒ si nuestro objetivo es estimar el **efecto total de A en Y**, NO necesitamos incluir a B en nuestro DAG.


Controlando en un mediador

Supongamos que incluimos a B.

A = Fumar

Y = Cáncer de pulmón

B = Daño en células del pulmón



¿Esperamos encontrar asociación entre A e Y **condicional** a B?

No. Es decir A es **independiente** de Y **condicional** a B ($A \perp Y | B$)


Prop 4: **condicionar** en un **mediador (B)** bloquea el flujo de **asociación** entre A e Y.

Controlando en un mediador

A = Fumar

Y = Cáncer de pulmón

B = Daño en células del pulmón



Prop 4: condicionar en un **mediador (B)** bloquea el flujo de **asociación** entre A e Y.


¿Qué pasa si para determinar el efecto causal de **Fumar** en **Cáncer de pulmón** controlamos por **B**?

Moralejas:

- Si queremos estimar el efecto total de A en Y, NO debemos controlar por B.
- Podemos cometer un sesgo al controlar por una variable errónea.

Controlando en un mediador

¿Qué pasa si, al condicionar en B, encontramos asociación entre A e Y?




A = Fumar

Y = Cáncer de pulmón

B = Daño en células del pulmón

Un DAG compatible con esos datos sería...




A = Fumar

Y = Cáncer de pulmón

B = Daño en células del pulmón

Efectos directo e indirecto



A = Fumar

Y = Cáncer de pulmón


B = Daño en células del pulmón

- **Efecto indirecto:** $A \rightarrow B \rightarrow Y$
- **Efecto directo:** $A \rightarrow Y$
- **Efecto total:** combinación de los efectos **directo** e **indirecto**.

Vimos que, para estimar el **efecto total** NO debíamos controlar por B.

¿Qué pasa si controlamos por B? ¿Qué efecto estaremos estimando?

Efectos directo e indirecto



A = Fumar

Y = Cáncer de pulmón

B = Daño en células del pulmón


Conclusión: si queremos estimar...

- el **efecto total**, NO debemos controlar por B.
- el **efecto directo**, debemos controlar por B.

Moraleja


Para determinar cuál es el análisis correcto de los datos, debemos tener en cuenta...

- la **estructura causal** de las variables involucradas.
- la **pregunta causal**.




Aplicación: Program.ar

Condicionando en Sector




Sin condicionar en Sector



Al principio de la clase concluimos que no debíamos condicionar en Sector.

Veamos qué nos dicen los DAGs (las reglas de d-separación).

Aplicación: Program.ar



A = Curso

Y = Salario

Z = Sector

¿Qué efecto nos interesa estimar? ¿el directo o el total?

Entonces, ¿debemos controlar por Sector?

Recapitulando...


Un DAG es un modelo...

- **causal**: representa la estructura causal de las variables
- **estadístico**: de él se deducen asociaciones e independencias entre las variables


Por eso los DAGs nos sirven para hallar el método correcto de análisis de los datos para responder a la pregunta causal.

Repasemos qué asociaciones e independencias podemos deducir según lo que vimos hasta ahora.

Asociaciones marginales




Prop 1: camino dirigido de A a Y $\Rightarrow$ posible asociación entre A e Y




Prop 2: causa común entre A e Y $\Rightarrow$ posible asociación entre A e Y

Independencias condicionales



Prop 3: al condicionar en una **causa común** bloqueamos el flujo de asociación.



Prop 4: al condicionar en un **mediador** bloqueamos el flujo de asociación.

La justificación formal de todas estas reglas involucra a la teoría de variables contrafactuales y modelos de ecuaciones estructurales.

(ver Hernán MA, Robins JM (2020). Causal Inference: What If)

Sesgo de selección


Configuraciones básicas

Chain (cadena)



Z: mediador

Fork (tenedor)




Z: causa común



Confusión

Collider (colisionador)



Z: efecto común



Sesgo de selección

Veamos qué independencias y asociaciones se desprenden de un collider.

Ejemplo motivador

Ejemplo Basquet

- Tenemos un conjunto de datos de jugadores de basquet.
- Objetivo: determinar si la **altura** influye en la **velocidad** para correr.



Los datos

Diccionario

Datos

- **Altura:** altura (en m)
- **Velocidad:** velocidad para correr (en km/h)
- **NBA:** indicadora de jugar en la NBA
(1 = Sí; 0 = No)

Análisis de datos


- **Pregunta causal:**

¿La altura tiene influye en la velocidad para correr?


- **Objetivo:** estimar el **efecto (causal)** de la **Altura** en la **Velocidad**.
- **Análisis**
 - Variable de respuesta: **Velocidad**
 - Variable explicativa: **Altura**

¿¿¿Debemos **controlar** por **NBA**???

Sin controlar por NBA




Sin controlar por NBA




`lm(velocidad ~ altura)`

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	57.23	4.09	14.00	<2e-16 ***
altura	-1.28	2.20	-0.58	0.56

Controlando por NBA



Controlando por NBA



```
lm(velocidad ~ altura * nba)
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	91.54	4.09	22.39	<2e-16 ***
altura	-20.94	2.22	-9.41	<2e-16 ***
nba1	97.84	13.00	7.53	7.94e-14 ***
altura:nba1	-41.89	6.662	-6.28	3.95e-10 ***

Controlando por NBA

```
lm(velocidad ~ altura * nba)
```


	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	91.54	4.09	22.39	<2e-16 ***
altura	-20.94	2.22	-9.41	<2e-16 ***
nba1	97.84	13.00	7.53	7.94e-14 ***
altura:nba1	-41.89	6.662	-6.28	3.95e-10 ***

$$\widehat{\text{velocidad}} = \hat{\beta}_0 + \hat{\beta}_1 \cdot \text{altura} + \hat{\beta}_2 \cdot \text{nba} + \hat{\beta}_3 \cdot (\text{altura} \times \text{nba})$$

Pendiente:

- NBA = 0: $\hat{\beta}_1 = -20.94$
- NBA = 1: $\hat{\beta}_1 + \hat{\beta}_3 = -20.94 - 41.89 = -62.83$

Controlando por NBA





$$\widehat{\text{velocidad}} = \hat{\beta}_0 + \hat{\beta}_1 \cdot \text{altura} + \hat{\beta}_2 \cdot \text{nba} + \hat{\beta}_3 \cdot (\text{altura} \times \text{nba})$$

Pendiente:

- NBA = 0: $\hat{\beta}_1 = -20.94$
- NBA = 1: $\hat{\beta}_1 + \hat{\beta}_3 = -62.83$

Paradoja de Simpson



La asociación entre la **Altura** y la **Velocidad** cambia según si controlamos o no por **NBA**

¿Cuál es el análisis correcto?

Intentemos responderlo intuitivamente (sin DAGs).

DAG en Ejemplo Basquet

A

A = Altura


Y = Velocidad para correr

Z

Z = Jugar en la NBA

Y

DAG en Ejemplo Basquet




A = Altura

Y = Velocidad para correr

Z = Jugar en la NBA

DAG en Ejemplo Basquet



A = Altura

Y = Velocidad para correr

Z = Jugar en la NBA

Z es un efecto común de A e Y.



Collider


Configuraciones básicas

Chain (cadena)



Z: mediador

Fork (tenedor)




Z: causa común



Confusión

Collider (colisionador)



Z: efecto común



Sesgo de selección

Veamos qué independencias y asociaciones se desprenden de un **collider**.

Ejemplo dados

Tiramos dos dados y definimos

$D1$ = Nro. del dado 1


$D2$ = Nro. del dado 2



¿Hay asociación entre $D1$ y $D2$?


Ejemplo dados

```
1 set.seed(412)
2 dado1 <- sample(1:6, 1000, replace = TRUE)
3 dado2 <- sample(1:6, 1000, replace = TRUE)
```



Ejemplo dados con suma

Pintemos de azul las observaciones que suman 7 ($S = D1 + D2$).



$D1 = \text{Nro. del dado 1}$

$D2 = \text{Nro. del dado 2}$

$S = D1 + D2$

¿Hay asociación entre $D1$ y $D2$ condicional a que $S = 7$?

Conclusión: $D1$ y $D2$ son marginalmente independientes, pero al condicionar en S se vuelven dependientes.

DAG en ejemplo dados

D1

D1 = Nro. del dado 1


D2 = Nro. del dado 2

S

$S = D1 + D2$

D2

DAG en ejemplo dados



D1 = Nro. del dado 1

D2 = Nro. del dado 2

$S = D1 + D2$


¿Qué asociaciones e independencias se deducen de un collider?

D1 y D2 son marginalmente independientes ($D1 \perp D2$).


pero...

D1 y D2 están asociadas condicional a S ($D1 \not\perp D2 | S$).

Collider



Prop 5: un **collider** bloquea el flujo de **asociación** entre sus causas.



Prop. 6: condicionar en un **collider** abre el flujo de **asociación** entre sus causas.

Configuraciones básicas


Flujos de asociación y causalidad

Chain




- asociación: sí
- causalidad: sí

Fork



- asociación: sí
- causalidad: no

Collider




- asociación: no
- causalidad: no

Configuraciones básicas - flujos


Chain



Fork



Collider




Conclusiones:

- dos variables A e Y están **asociadas** únicamente si una causa la otra o si tienen una causa en común.
- A tiene un **efecto causal** en Y únicamente si hay un camino dirigido de A a Y.

Configuraciones básicas con control


¿Fluye la asociación?

Chain




No

Fork



No


Collider




Sí

Colliders vs. Confusores y Mediadores

Los **colliders** funcionan al revés de los **confusores** y los **mediadores**:




Cuando NO **condicionamos** en ellos, **bloqueamos** el flujo de asociación.



Cuando **condicionamos**, lo **abrimos**.

Ejemplo Basquet

Ejemplo Basquet con DAGs



A = Altura


Y = Velocidad para correr

Z = Jugar en la NBA

Si queremos estimar el efecto causal de la **Altura** en la **Velocidad para correr** ¿debemos controlar por **NBA**?

Recordemos: debemos bloquear todos los caminos (de **A** a **Y**) por los cuales fluye la **asociación** pero no la **causalidad** y dejar abiertos todos los caminos por los cuales fluye la **causalidad**.

Análisis correcto en Ejemplo Basquet



A = Altura

Y = Velocidad para correr


Z = Jugar en la NBA

No debemos controlar por ninguna variable ya que no hay ningún camino por el cual fluya la asociación y no la causalidad.

Más aún, si controlamos por **Z** abriremos un camino por el cual fluye la asociación y no la causalidad, con lo cual introduciremos un **sesgo** conocido como **sesgo de selección**.

Sesgo de selección: sesgo en la estimación de un efecto causal provocado por controlar por un collider.

Análisis correcto en Ejemplo Basquet




```
lm(velocidad ~ altura)
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	57.23	4.09	14.00	<2e-16 ***
altura	-1.28	2.20	-0.58	0.56

Conclusión: no hay efecto de la **Altura** en la **Velocidad** para correr.

(Ser más bajo no te hace correr más rápido.)

Sesgo de selección




A = Altura

Y = Velocidad para correr

Z = Jugar en la NBA


Sesgo de selección: sesgo en la estimación de un efecto causal provocado por controlar por un collider.



¿Por qué se llama “sesgo de selección”?

Ejemplo NBA


- Objetivo: determinar si la **altura** influye en la **velocidad** para correr.
- Tenemos un conjunto de datos de jugadores de la NBA.
- Variables: **Altura** y **Velocidad**



DAG


A = Altura

Y = Velocidad




Ejemplo NBA

- Objetivo: determinar si la **altura** influye en la **velocidad** para correr.
- Tenemos un conjunto de datos de jugadores de la NBA.
- Variables: **Altura** y **Velocidad**



DAG verdadero




A = Altura

Y = Velocidad

Z = Jugar en la NBA

Ejemplo NBA

DAG verdadero



A = Altura

Y = Velocidad

Z = Jugar en la NBA

Moraleja: si hay un collider en el cual estamos condicionando, esa variable debe estar en el DAG.

Cuestionario


Para la clase que viene responder el cuestionario 2 disponible en el github y en [este link](#)

Recapitulando

Para hallar el análisis correcto que permita evaluar si una variable **T** tiene efecto en otra variable **Y**, es necesario...

1. Dibujar el DAG causal

Ejemplo covid-27




T = Tratamiento

Y = Muerte

Z = Condición


1. DAG causal



1. **Presencia de flecha de X a Y:** puede haber un efecto causal de X a Y.
2. **Ausencia de flecha de X a Y:** NO hay efecto causal de X a Y.
3. Toda **causa común** entre dos variables del DAG debe estar también en el DAG (incluso aunque no haya sido medida).
4. Toda **efecto común** entre dos variables del DAG (en el cual estemos condicionando) debe estar también en el DAG.

Los **supuestos causales** provienen del **conocimiento experto**, no de los **datos**.

2. Analizar caminos entre T e Y




T = Tratamiento

Y = Muerte

Z = Condición

Debemos identificar todos los caminos de T a Y por los que fluye la **asociación** y luego identificar por cuáles de ellos también fluye la **causalidad**.

3. Decidir por qué variables controlar



T = Tratamiento

Y = Muerte


Z = Condición

Debemos controlar por las variables necesarias para

- **bloquear** (y no abrir) todos los caminos por los que fluye la **asociación** pero no la **causalidad**.
- dejar **abiertos** todos los caminos por los que fluye la **causalidad**.

Para ello debemos usar las **Reglas de d-separación**.


Reglas de d-separación




Prop 1: camino dirigido de A a Y $\Rightarrow$
posible asociación entre A e Y




Prop 2: causa común entre A e Y $\Rightarrow$
posible asociación entre A e Y



Reglas de d-separación




Prop 3: al **condicionar** en una **causa común** bloqueamos el flujo de asociación.




Prop 4: al **condicionar** en un **mediador** bloqueamos el flujo de asociación.

Reglas de d-separación




Prop 5: un **collider** bloquea el flujo de **asociación** entre sus causas.



Prop. 6: condicionar en un **collider** abre el flujo de **asociación** entre sus causas.

Reglas de d-separación



Prop. 7: condicionar en un **efecto de un collider** también abre el flujo de **asociación** entre las causas.

